

# Исследование и разработка методов автоматического профилирования автора русскоязычного текста

---

ИИПАмд-21 Филиппов Никита Андреевич

Научный руководитель: доцент кафедры ИС Воронина В.В.

## **Таргетированная реклама - ключевой инструмент развития бизнеса**

Основа таргетирования - цифровой профиль пользователя.

Алгоритмы персонализации опираются на данные профиля (пол, возраст, интересы). От их качества зависят основные бизнес-метрики (показатель эффективности рекламы, конверсия и стоимость привлечения клиента).

### **Но профили ненадёжны**

- Пользователи оставляют поля пустыми или намеренно искажают информацию.
- Классический ручной сбор делает таргетинг неэффективным.

### **Решение: автоматическое профилирование по пользовательским текстам**

Цифровые тексты, создаваемые пользователями в социальных сетях, блогах, комментариях, отзывах и форумах, содержат цифровой отпечаток автора. Методы NLP позволяют извлечь из них атрибуты без прямого опроса.

# Существующие исследования

Стилометрические и лингвистические признаки позволяют определять пол и возраст автора русскоязычного текста с точностью выше случайной.

- **Литвинова Т.А. и др. (Rusldiolect, BlogsGenderAge):**
  - Показана устойчивая корреляция пола/возраста с морфологическими и синтаксическими метриками;
  - Сформированы специализированные корпуса для русского языка;
  - Составной профиль (пол + три возрастные группы): точность **47%** при базовом уровне **29%**.
- **Соболев А.А. и др. (2022):**
  - Методика определения возраста на основе метрик удобочитаемости и лексического разнообразия;
  - Точность **около 68%** без верификации данных по фотографиям (оригинальные результаты выше получены при дополнительной фильтрации корпуса по фото).
- **Зарубежные работы (Argamon, Koppel, Schler):** Для английского языка точность классификации пола достигает 70–84%

# Ограничения существующих решений

## Методические ограничения

Существующие методы автоматического профилирования обладают двумя существенными недостатками:

- **Контентная зависимость.** Методы, основанные на тематике текста (ключевые слова, частота упоминаний), показывают высокую точность только в рамках одной предметной области и резко теряют качество при смене жанра или темы.
- **Высокие требования к качеству текста.** Большинство стилометрических подходов хорошо работают на структурированных и грамотных, синтаксически правильных текстах. Это делает их малоэффективными при работе с живыми цифровыми текстами (сленг, эмодзи, намеренные искажения, нарушение пунктуации).

Таким образом, актуальной является разработка методики профилирования, которая, с одной стороны, не зависит от тематики, а с другой - применима к "живым" текстам без агрессивной фильтрации.

Разработка методики автоматического профилирования автора русскоязычного текста и экспериментальное исследование его применимости для повышения точности персонализации цифровых платформ.

# Задачи исследования

1. Провести анализ существующих методик автоматического профилирования, выявить их ограничения;
2. Обосновать выбор формальных лингвистических признаков, применимых для профилирования;
3. Разработать методику извлечения и агрегации признаков из русскоязычного текста;
4. Построить и обучить модели классификации, реализующие предложенную методику;
5. Спроектировать и разработать веб-сервис, реализующий функциональность автоматического профилирования автора текста;
6. Провести экспериментальную оценку применимости разработанной методики для задач персонализации цифровых платформ.

- **Объект:** Процессы и методики анализа текстов для выявления характеристик автора
- **Предмет:** Алгоритмы и программные решения для автоматического профилирования автора русскоязычного текста

Разработка тематически-независимой методики извлечения и агрегации лингвистических признаков из русскоязычного текста, позволяющей достичь точности профилирования, сопоставимой с существующими подходами, при минимальной предобработке исходного материала

# Модель 'Как есть'



- Зависимость от профильных данных
- Низкая релевантность таргетинга
- Высокий САС

# Модель 'Как должно быть'



- Интеграция модуля автоматического профилирования
- Обогащение профилей на основе контента
- Повышение релевантности и снижение САС

В работе применяется **стилометрический подход**, который:

- Опирается на формальные статистические признаки (лексика, морфология, синтаксис, пунктуация);
- Не зависит от тематики текста;
- Устойчив к смене жанра и предметной области.

Контентные подходы (на основе ключевых слов и тематики) не используются ввиду их сильной зависимости от предметной области.

# Извлекаемые признаки

## Обоснование выбора

Для стилометрического профилирования без привязки к тематике необходим комплексный охват разных уровней языка: лексического, морфологического, синтаксического и пунктуационного. Каждый уровень даёт независимые сигналы о стиле автора.

## Категории признаков (более 80 метрик):

- **Лексические и статистические:** TTR, средняя длина слова, доля редких слов - отражают словарный запас и разнообразие речи.
- **Морфологические:** частотность частей речи, биграммы POS - фиксируют грамматические предпочтения.
- **Синтаксические:** длина предложения, индексы формальности - характеризуют сложность и структуру фраз.
- **Пунктуационные и сущности:** частотность знаков, выделение URL, смайлов, дат - маркеры эмоциональности и цифрового стиля.

## Ключевые атрибуты профиля

Авторский профиль может включать различные характеристики: демографические, социальные, психологические и поведенческие. Среди них выделяются **первичные атрибуты** — пол и возраст, которые оказывают наиболее значимое влияние на стиль письма и служат основой для определения остальных характеристик.

## Выбор атрибутов для исследования

В рамках данной работы для анализа выбраны **пол** и **возрастная группа** автора. Этот выбор обусловлен следующими причинами:


- Наличие размеченных данных для русского языка (корпус BlogsGenderAge)
- Хорошо изученные лингвистические маркеры
- Прямое практическое применение в задачах персонализации

В работе исследованы два варианта:

- **Плоская классификация:** одна модель предсказывает все атрибуты одновременно (пол+возраст).
- **Иерархическая (каскадная):** сначала определяется пол, затем внутри каждой половой группы — возраст.

Согласно исследованиям, каскадные схемы проявляют разную эффективность на несбалансированных данных, но уступают лучшей плоской модели по общей точности.

# Методика обработки текста



## Основные шаги:

1. Минимальная предобработка (удаление html-разметки, ё→е);
2. Проверка допустимой длины и парности кавычек;
3. Выделение 14 типов сущностей (URL, email, даты, смайлы);
4. Лемматизация и морфологическая разметка (POS);
5. Извлечение 80+ лингвистических метрик.

## Ключевые особенности:

- Обработка живого текста с особенностями пунктуации, сленга, эмодзи;
- Тематическая независимость.

## Линейные и вероятностные


- **LR** - успешно применялась для определения пола (точность 76.2%), прозрачна, удобна как базовая модель.
- **SVM** - основа многих стилометрических работ: точность до 84.3% на блогах.
- **Naive Bayes** - быстрый вероятностный классификатор.

## Ансамбли и нейросети

- **Random Forest** - хорошие показатели при атрибуции текстов;
- **Gradient Boosting** - наилучшую точность задачах анализа тональности, лидер во многих соревнованиях.
- **MLP** и **KNN** - позволяют оценить выигрыш от нелинейных методов.

Выбор покрывает основные парадигмы машинного обучения и мотивирован успехами в близких задачах. Это даёт возможность найти наилучший баланс точности и стабильности на русскоязычных текстах.

# Программный прототип



Для демонстрации применимости разработанной методики создан программный прототип.

Он реализует полный цикл профилирования автора: от извлечения лингвистических признаков до определения пола и возраста автора.

Пользователь может использовать для прогнозирования одну из предложенных моделей

Подробности архитектуры и реализации — в приложении.

Для задач классификации пола и возраста основным критерием является **доля правильных ответов**:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Прозрачность:** точность напрямую отражает практическую применимость в бизнес-задачах (персонализация, таргетинг).
- **Сравнимость:** большинство исследований (Литвинова, Соболев, Коррел) используют ассигасу, что позволяет корректно сопоставлять результаты.
- **Дополнительно:** для анализа дисбаланса классов используется F1-мера.

Все эксперименты проводились на стратифицированной отложенной выборке с сохранением распределения целевых классов.

# Сводка результатов экспериментов

Оценка проводилась на исходном, нефильтованном датасете, собранным Т.Литвиновой. Выделялись подвыборки по полу автора, возрастной группе (молодые / взрослые) и длине текста (короткие — менее 2000 символов, длинные — более 2000 символов). Для оценки стабильности вычислялись стандартное отклонение и коэффициент вариации точности по блокам, использовался тест Левена.

## Результаты:

- **Пол:** лучшая точность — SVC-RBF (67%), наиболее стабилен — SVC-poly.
- **Возраст:** лучшие результаты — SVC-RBF и GBM (до 65%).  
Гендерно-специализированные модели стабильнее.
- **Составной профиль:** максимальная точность (45%) у flat\_svc\_rbf, равномернее распознают классы flat\_svc\_poly и flat\_svc\_linear.
- **Каскадные схемы:** дают выигрыш на проблемных подвыборках (женщины, взрослые, длинные тексты).

Детальные графики и матрицы ошибок вынесены в приложение.

# Результаты экспериментов

Разработанные модели способны извлекать из текста информацию, позволяющую автоматически определять пол и возрастную группу автора.

- **Компромисс точности и баланса:** модель `flat_svc_rbf` показала наилучшую суммарную точность, однако `flat_svc_poly` и `flat_svc_linear` обеспечивают более равномерное распознавание редких классов
- **Ограничение текущих признаков:** лучшие модели лишь умеренно превосходят базовую стратегию, что указывает на слабый сигнал в данных - различия между группами авторов выражены недостаточно явно

## Вывод

Предложенная методика обеспечивает сопоставимую точность определения пола и возраста автора и демонстрирует устойчивость к изменению тематики текста.

# Сравнение результатов

| Задача                          | Предложенная методика | Ведущие исследования      |
|---------------------------------|-----------------------|---------------------------|
| Пол                             | SVC-RBF: 67%          | ≈ 70% (Литвинова, Koppel) |
| Возраст (бинарный)              | GBM: до 65%           | ≈ 68% (Соболев, без фото) |
| Составной профиль (пол+возраст) | flat_svc_rbf: 45%     | ≈ 47% (Литвинова)         |

## Ограничения существующих подходов

- **Литвинова:** Фильтрация текстов по формальным признакам, исключаются короткие и неструктурированные тексты.
- **Соболев:** Верификация возраста авторов по фотографиям - в реальных цифровых данных такая информация недоступна. При смене тематики или жанра текста точность резко падает.

## Ключевой вывод

Предложенная **тематически-независимая методика** достигает точности, **сопоставимой** с лучшими существующими подходами, которые часто требуют глубокой очистки текста или привязки к тематике.

При этом методика применима к живым цифровым текстам (сленг, эмодзи, нарушения пунктуации) без потери качества.


## Результаты исследования

- **Разработана формализованная методика** извлечения лингвистических признаков из русскоязычного текста с минимальной предобработкой и без привязки к тематике.
- **Программный прототип** реализует полный цикл - от сырого текста до составного профиля.
- **Экспериментально подтверждена сопоставимость** с ведущими исследованиями: пол - 67%, возраст - 65%, составной профиль - 45%.



Спасибо за внимание!

Вопросы?



# Стабильность. Модели прогнозирования пола




# Стабильность. Модели прогнозирования возрастной группы




# Стабильность. Модели прогнозирования профиля




# Обобщенность. Оценки моделей



# Обобщенность. Лучшие модели по подвыборкам




# Обобщенность. Оценка смещения на парных подвыборках




- Python: FastAPI, Scikit-learn, Pandas, Numpy, Seaborn, Matplotlib, Scipy
- NLP: Natasha, pymorphy2, nltk
- База данных: PostgreSQL
- Веб-сервер: Nginx
- Клиент: jQuery, Panini, Gulp
- Асинхронная обработка: Celery

# Диаграмма компонентов




# Архитектура развертывания системы




# Диаграмма вариантов использования



# Диаграмма классов системы



# Последовательность обработки запроса



# Интерфейс пользователя. Главная страница

Анализ текста

0 моделей

## Анализ текста

Пример текстаЗагрузить файл

ва. Итак, не можешь не писать – не пиш. Усмири свой пыл любым способом, который тебе знаком лучше, чем мне (у меня есть свои, но говорить о них слишком интимно, мы пока ещё не в такой дружбе, знаешь ли). Не получилось? Что ж, напиши всё, что ты хочешь. Написал? Молодец. Теперь легче стало? Ну, то есть, получил отдохновение? Если нет, то значит это не твой, брось – и не возвращай мне глупости, вроде той, что если бы написал лучше, то отдохновение пришло, а потому стоит писать лучше. Вот уж дуди! Ничего этого не знаешь. Если не получишь отдохновения, значит писать тебе и не стоило, а стоит поискать отдохновение в другом. Что ты говорил? Получил, но не отдохновение? А что же, милый мой. Ну-ка, так-так: получил текст (можешь, мне не говорить, это не интересно), и лёгкость какую-то, радость может даже. Так, у меня для тебя две новости: одна плохая, а другая хорошая. Плохая: в перечень твоих интимных вещей входит писание текстов. Хорошая: в перечень твоих интимных вещей входит писание текстов. Как то есть что я имею в виду? Какой же ты глупый, поспею. С тобой что-то не так, тебе нужно писать там, где другие любят друг друга, едят, танцуют и развлекаются как могут. Это же не очень хорошо, согласен? Зато, заметь, зато ты нашёл очень дешёвую интимную вещь: не надо даже особенно тратиться, это даже безобиднее мастурбации, так что пиш-пиши. Получил радость, лёгкость – и, теперь слушай внимательно! – унынькошь написанное. Ведь оно уже сделало своё дело в твоём отношении, умеи быть благодарным. Что, куда ты прятал, свою бумажку? Зачем она тебе? Дорогой мой, ты так можешь от безобидной интимности перейти к обидной, уж не фетишист ли ты? Что? Ты хочешь это кому-нибудь показать? Ох, я понял: экзгибиционизм. Не надо, умоляю тебе, не стоит, ну, погоди, хорошо-хорошо, повесь на стенку ВКонтакте, отфисбучь свою писанину. Доволен? Нет? Чего же ты теперь ждёшь? Лайков? Вот, пожалуйста, не надо следить за плагатом тех, кто похвалил и кто шёл, и кого из плевых ты выложишь теперь, любить, похвалить, как всё это работает? и на кого из влиятельных ты

3230/10000 символов

Универсальный ...Прогнозировать

### Результаты прогноза

Профиль автора



Молодой мужчина

Пол

Женщина

Мужчина

66.6%

Порог > 50%

Возрастная группа

Молодой

Взрослый

37.1%


Порог > 50%

### Модели для прогнозирования

Универсальный оптимумСправедливая модельКорректор смещения

36

# Интерфейс пользователя. Результат профилирования



# Интерфейс пользователя. Информация о модели

Анализ текста

О моделях

Информационный раздел

Автоматическое профилирование

Универсальный оптимум

Справедливая модель

Корректор смещения

## Универсальный оптимум (flat\_svc\_rbf)

### Назначение

Модель «Универсальный оптимум» представляет собой плоский классификатор на основе метода опорных векторов с радиальным базисным ядром (RBF), который одновременно предсказывает пол и возраст автора текста, объединяя их в четыре возможные категории:

- молодая женщина,
- взрослая женщина,
- молодой мужчина,
- взрослый мужчина.

Это базовая рекомендуемая модель для большинства практических сценариев, когда требуется получить максимальную общую точность на разнородных текстах без дополнительных требований к балансу классов. Она наилучшим образом работает на мужской аудитории, молодых авторах и коротких текстах, демонстрируя стабильные результаты на всех типах данных.

### Особенности подготовки данных

Модель чувствительна к выбросам, мультиколлинеарности и масштабу признаков, поэтому этап предобработки включает:

- **Робастное масштабирование** (RobustScaler) для всех признаков - устойчиво к выбросам.
- **Преобразование Йео-Джонсона** для приближения распределений к нормальному.
- **Отбор признаков** с помощью SelectKBest (F-классификации) на каждом фолде кросс-валидации.

### Как обучалась модель

Целевая переменная формировалась как комбинация пола и возраста:  
gender \* 2 + age (0 - молодая женщина, 1 - взрослая женщина, 2 - молодой мужчина, 3 - взрослый мужчина).

Оптимальные гиперпараметры найдены с помощью GridSearchCV:

- C = 1 (штраф)
- gamma = 0.2 (коэффициент ядра RBF)
- kernel = 'rbf'
- class\_weight = 'balanced'
- отбор признаков: использовать все (k = 'all').

Диаграмма рассеивания точности модели относительно скорости обучения показана ниже