

Исследование и разработка методов автоматического профилирования автора русскоязычного текста

ИИПАмд-21 Филиппов Никита Андреевич

Научный руководитель: доцент кафедры ИС Воронина В.В.

Введение

Таргетированная реклама - ключевой инструмент развития бизнеса

Основа таргетирования - цифровой профиль пользователя.

Алгоритмы персонализации опираются на данные профиля (пол, возраст, интересы). От их качества зависят основные бизнес-метрики (показатель эффективности рекламы, конверсия и стоимость привлечения клиента).

Но профили ненадёжны

- Пользователи оставляют поля пустыми или намеренно искажают информацию.
- Классический ручной сбор делает таргетинг неэффективным.

Решение: автоматическое профилирование по тексту

Тексты (посты, комментарии) содержат цифровой отпечаток автора.

Методы NLP позволяют извлечь из них демографические характеристики без прямого опроса.

Существующие исследования

Стилометрические и лингвистические признаки позволяют определять пол и возраст автора русскоязычного текста с точностью выше случайной.

- **Литвинова Т.А. и др. (Rusldiolect, BlogsGenderAge):**
 - Показана устойчивая корреляция пола/возраста с морфологическими и синтаксическими метриками;
 - Сформированы специализированные корпуса для русского языка;
 - Составной профиль (пол + три возрастные группы): точность **47%** при базовом уровне **29%**.
- **Соболев А.А. и др. (2022):**
 - Методика определения возраста на основе метрик удобочитаемости и лексического разнообразия;
 - Точность **около 68%** без верификации данных по фотографиям (оригинальные результаты выше получены при дополнительной фильтрации корпуса по фото).
- **Зарубежные работы (Argamon, Koppel, Schler):** Для английского языка точность классификации пола достигает 70–84%

Ограничения существующих решений

Методологические ограничения

Существующие методы автоматического профилирования обладают двумя существенными недостатками:

- **Контентная зависимость.** Методы, основанные на тематике текста (ключевые слова, частота упоминаний), показывают высокую точность только в рамках одной предметной области и резко теряют качество при смене жанра или темы.
- **Высокие требования к качеству текста.** Большинство стилометрических подходов хорошо работают на структурированных и грамотных, синтаксически правильных текстах. Это делает их малоэффективными при работе с живыми цифровыми текстами (сленг, эмодзи, намеренные искажения, нарушение пунктуации).

Таким образом, актуальной является разработка методологии профилирования, которая, с одной стороны, не зависит от тематики, а с другой - применима к "живым" текстам без агрессивной фильтрации.

Цели и задачи

Разработка метода автоматического профилирования автора русскоязычного текста и экспериментальное исследование его применимости для повышения точности персонализации цифровых платформ.

Задачи исследования

1. Провести анализ существующих методов автоматического профилирования, выявить их ограничения;
2. Обосновать выбор формальных лингвистических признаков, применимых для профилирования;
3. Разработать методологию извлечения и агрегации признаков из русскоязычного текста;
4. Построить и обучить модели классификации, реализующие предложенную методологию;
5. Спроектировать и разработать веб-сервис, реализующий функциональность автоматического профилирования автора текста;
6. Провести экспериментальную оценку применимости разработанной методологии для задач персонализации цифровых платформ.

- **Объект:** Процессы и методы анализа текстов для выявления характеристик автора
- **Предмет:** Алгоритмы и программные решения для автоматического профилирования автора русскоязычного текста

Разработка тематически-независимой методологии извлечения и агрегации лингвистических признаков из русскоязычного текста, позволяющей достичь точности профилирования, сопоставимой с существующими подходами, при минимальной предобработке исходного материала


Теоретическое описание и методология

Модель 'Как есть'



- Зависимость от профильных данных
- Низкая релевантность таргетинга
- Высокий САС

Модель 'Как должно быть'



- Интеграция модуля автоматического профилирования
- Обогащение профилей на основе контента
- Повышение релевантности и снижение САС

Подходы извлечения информации из текста

Стилометрический подход: лексика, морфология, синтаксис, пунктуация, TTR, длины слов/предложений

- Фокус на формальных характеристиках
- Устойчивость к тематическим сдвигам
- Меньшая зависимость от домена
- Чувствителен к объёму текста, уязвим к обфускации

Контекстный подход: ключевые слова, тематика, NER

- Фокус на тематике и семантике
- Высокая интерпретируемость
- Сильная зависимость от домена

Обоснование выбора

Для стилометрического профилирования без привязки к тематике необходим комплексный охват разных уровней языка: лексического, морфологического, синтаксического и пунктуационного. Каждый уровень даёт независимые сигналы о стиле автора.

Категории признаков (более 80 метрик):

- **Лексические и статистические:** TTR, средняя длина слова, доля редких слов - отражают словарный запас и разнообразие речи.
- **Морфологические:** частотность частей речи, биграммы POS - фиксируют грамматические предпочтения.
- **Синтаксические:** длина предложения, индексы формальности - характеризуют сложность и структуру фраз.
- **Пунктуационные и сущности:** частотность знаков, выделение URL, смайлов, дат - маркеры эмоциональности и цифрового стиля.

Ключевые атрибуты профиля

Авторский профиль может включать различные характеристики: демографические, социальные, психологические и поведенческие. Среди них выделяются **первичные атрибуты** — пол и возраст, которые оказывают наиболее значимое влияние на стиль письма и служат основой для определения остальных характеристик.

Выбор атрибутов для исследования

В рамках данной работы для анализа выбраны **пол** и **возрастная группа** автора. Этот выбор обусловлен следующими причинами:

- Наличие размеченных данных для русского языка (корпус BlogsGenderAge)
- Хорошо изученные лингвистические маркеры
- Прямое практическое применение в задачах персонализации

Подходы в классификации составного профиля

Плоская классификация

- Одна модель для всех атрибутов
- Простота реализации
- Экспоненциальный рост классов
- Не работает в случае гетерогенных целевых переменных

Иерархическая классификация

- Последовательное уточнение атрибутов
- Использование специализированных моделей
- Более высокая точность

Алгоритм извлечения и подготовки признаков


Разработана последовательность обработки русскоязычного текста, включающая:

1. Первичную предобработку и контроль структурной корректности;
2. Выделение 14 типов сущностей (email, URL, даты, смайлы и др.) с помощью ансамбля правил и NER;
3. Лингвистическую разметку: леммы, POS, морфология;
4. Извлечения вектора из 80+ стилометрических и контентных метрик.

Разработанный алгоритм:

- Учитывает особенности русской морфологии;
- Адаптируется к необработанным текстам соцсетей;
- Поддерживает расширение для выделения новых типов сущностей и извлечения дополнительных метрик.

Алгоритм обработки документа



Линейные и вероятностные

- **LR** - успешно применялась для определения пола (точность 76.2%), прозрачна, удобна как базовая модель.
- **SVM** - основа многих стилометрических работ: точность до 84.3% на блогах.
- **Naive Bayes** - быстрый вероятностный классификатор.

Ансамбли и нейросети

- **Random Forest** - хорошие показатели при атрибуции текстов;
- **Gradient Boosting** - наилучшую точность задачах анализа тональности, лидер во многих соревнованиях.
- **MLP** и **KNN** - позволяют оценить выигрыш от нелинейных методов.


Выбор покрывает основные парадигмы машинного обучения и мотивирован успехами в близких задачах. Это даёт возможность найти наилучший баланс точности и стабильности на русскоязычных текстах.

Проектирование системы


Диаграмма вариантов использования



Диаграмма классов системы



Последовательность обработки запроса



Интерфейс пользователя. Главная страница

Анализ текста

0 моделей

Анализ текста

Пример текстаЗагрузить файл

ва. Итак, не можешь не писать – не пиш. Усмири свой пыл любым способом, который тебе знаком лучше, чем мне (у меня есть свои, но говорить о них слишком интимно, мы пока ещё не в такой дружбе, знаешь ли). Не получилось? Что ж, напиши всё, что ты хочешь. Написал? Молодец. Теперь легче стало? Ну, то есть, получил одобрение? Если нет, то значит это не твой, брось – и не возвращай мне пустоты, вроде той, что если бы написал лучше, то одобрение пришло, а потому стоит писать лучше. Вот уж дуди! Ничего этого не значить. Если не получи одобрения, значит писать тебе я не стою, а стоит поискать одобрения в другом. Что ты говорил? Получил, но не одобрение? А что же, милый мой. Ну-ка, так-так: получил текст (можешь мне не говорить, это не интересно), и лёгкость какую-то, радость может даже. Так, у меня для тебя две новости: одна плохая, а другая хорошая. Плохая: в перечень твоих интимных вещей входит писание текстов. Хорошая: в перечень твоих интимных вещей входит писание текстов. Как то есть что я имею в виду? Какой же ты глупый, поспею. С тобой что-то не так, тебе нужно писать там, где другие любят друг друга, едят, танцуют и развлекаются как могут. Это же не очень хорошо, согласен? Зато, заметь, зато ты нашёл очень дешёвую интимную вещь: не надо даже особенно тратиться, это даже безобиднее мастурбации, так что пиш-пиши. Получил радость, лёгкость – и, теперь слушай внимательно! – уныточье написанное. Ведь оно уже сделало своё дело в твоём отношении, умеи быть благодарным. Что, куда ты простишь свою бумажку? Зачем она тебе? Дорогой мой, ты так можешь от безобидной интимности перейти к обидной, уж не фетишист ли ты? Что? Ты хочешь это кому-нибудь показать? Ох, я понял: экзгибиционизм. Не надо, умоляю тебе, не стоит, ну, погоди, хорошо-хорошо, повесь на стенку ВКонтакте, отфисбучь свою писанину. Доволен? Нет? Чего же ты теперь ждёшь? Лайков? Вот, пожалуйста, не надо следить за плагатом тех, кто похвалил и кто шит, и кого из плевых ты выложишь теперь, любить, похвалить, как всё это работает? и на кого из влиятельных ты

3230/10000 символов

Универсальный ...Прогнозировать

Результаты прогноза

Профиль автора



Молодой мужчина

Пол

Женщина

Мужчина

66.6%

Порог > 50%

Возрастная группа

Молодой

Взрослый

37.1%

Порог > 50%

Модели для прогнозирования

Универсальный оптимумСправедливая модельКорректор смещения

21

Интерфейс пользователя. Результат профилирования

Результаты анализа

Исходный текст

ва. Итак, не можешь не писать - не пиш. Усмири свой пыл любым способом, который тебе знаком лучше, чем мне (у меня есть свои, но говорить о них слишком интимно, мы пока ещё не в такой дружбе, знаешь ли). Не получилось? Что ж, напиши всё, что ты хочешь. Написал? Молодец. Теперь легче стало? Ну, то есть получил отдохновение? Если нет, то значит это не твоё, брось - и не возвращай мне глупости, вроде той, что если бы написал лучше, то отдохновение пришло, а потому стоит писать лучше. Вот уж дурак! Ничего это не значит. Если не получил отдохновения, значит писать тебе и не стоило, а стоит поискать отдохновение в другом. Что ты говорил? Получил, но не отдохновение? А что же, милый мой. Нука, так-так: получил текст (можешь мне не говорить, это не интересно), и лёгкость какую-то, радость может даже. Так, у меня для тебя две новости: одна плохая, а другая хорошая. Плохая в перечне твоих интимных вещей входит писание текстов. Хорошая в перечне твоих интимных вещей входит писание текстов. Как то есть что и имею в виду? Какой же ты глупый, конечно. С тобой что не так, тебе нужно писать там, где другие любят друг друга, едят, танцуют и развлекаются как могут. Это же не очень хорошо, согласен? Зато, заметь, зато ты нашёл очень дешёвую интимную вещь: не надо даже особенно тратиться, это даже безобиднее мастурбации, так что пиш-пиши. Получил радость, лёгкость - и, теперь слушай внимательно! - уничтожь написанное. Ведь оно уже сделало своё дело в твоём отношении, умей быть благодарным. Что, куда ты прячешь свою бумажку? Зачем она тебе? Дорогой мой, ты так можешь от безобидной интимности перейти к обычной, уж не фетишист ли ты? Что?! Ты хочешь это кому-нибудь показать? Ох, я понял: эсбифицизм. Не надо, умоляю тебе, не стоит, ну, погоди, хорошо-хорошо, повесь на стену ВКонтакте, отфейсбучь свою писанину. Доволен? Нет?! Чего же ты теперь ждёшь? Лайков? Вот, пожалуйста, не надо следить за списком тех, кто лайкал и кто нет, и кого из первых ты


Решение модели

Профиль автора



Молодой мужчина

Пол



Возрастная группа



Извлеченные метрики

Лингвистические признаки

					×
symbols_length	46.812	sentences_count	69.000	long_sentences_proportion	0.449
unpopular_words_proportion	0.339	obscene_proportion	0.000	rare_words_proportion	0.318
type_token_ratio	0.214	normalized_shannon_entropy	1.038	mean_words_length	3.777
long_words_proportion	0.276	lexicon_size	3.551	lexical_diversity_per_sentence	2.203

Сущностная разметка

Частеречная разметка

Интерфейс пользователя. Информация о модели

Анализ текста

0 моделей

Информационный раздел

Автоматическое профилирование

Универсальный оптимум

Справедливая модель

Корректор смещения

Универсальный оптимум (flat_svc_rbf)

Назначение

Модель «Универсальный оптимум» представляет собой плоский классификатор на основе метода опорных векторов с радиальным базисным ядром (RBF), который одновременно предсказывает пол и возраст автора текста, объединяя их в четыре возможные категории:

- молодая женщина,
- взрослая женщина,
- молодой мужчина,
- взрослый мужчина.

Это базовая рекомендуемая модель для большинства практических сценариев, когда требуется получить максимальную общую точность на разнородных текстах без дополнительных требований к балансу классов. Она наилучшим образом работает на мужской аудитории, молодых авторах и коротких текстах, демонстрируя стабильные результаты на всех типах данных.

Особенности подготовки данных

Модель чувствительна к выбросам, мультиколлинеарности и масштабу признаков, поэтому этап предобработки включает:

- **Робастное масштабирование** (RobustScaler) для всех признаков - устойчиво к выбросам.
- **Преобразование Йео-Джонсона** для приближения распределений к нормальному.
- **Отбор признаков** с помощью SelectKBest (F-классификации) на каждом фолде кросс-валидации.

Как обучалась модель

Целевая переменная формировалась как комбинация пола и возраста:
gender * 2 + age (0 - молодая женщина, 1 - взрослая женщина, 2 - молодой мужчина, 3 - взрослый мужчина).


Оптимальные гиперпараметры найдены с помощью GridSearchCV:

- C = 1 (штраф)
- gamma = 0.2 (коэффициент ядра RBF)
- kernel = 'rbf'
- class_weight = 'balanced'
- отбор признаков: использовать все (k = 'all').



Диаграмма рассеивания точности модели относительно скорости обучения показана ниже

Эксперименты и результаты



Стабильность. Модели прогнозирования пола




Стабильность. Модели прогнозирования возрастной группы




Стабильность. Модели прогнозирования профиля




Обобщенность. Оценки моделей



Обобщенность. Лучшие модели по подвыборкам



Обобщенность. Оценка смещения на парных подвыборках



Результаты экспериментов

Разработанные модели способны извлекать из текста информацию, позволяющую автоматически определять пол и возрастную группу автора.

- **Компромисс точности и баланса:** модель `flat_svc_rbf` показала наилучшую суммарную точность, однако `flat_svc_poly` и `flat_svc_linear` обеспечивают более равномерное распознавание редких классов
- **Ограничение текущих признаков:** лучшие модели лишь умеренно превосходят базовую стратегию, что указывает на слабый сигнал в данных - различия между группами авторов выражены недостаточно явно

Вывод

Предложенная методология обеспечивает сопоставимую точность определения пола и возраста автора и демонстрирует устойчивость к изменению тематики текста.

Сравнение результатов

Задача	Предложенная методология	Ведущие исследования
Пол	SVC-RBF: 67%	$\approx 70\%$ (Литвинова, Koppel)
Возраст (бинарный)	GBM: до 65%	$\approx 68\%$ (Соболев, без фото)
Составной профиль (пол+возраст)	flat_svc_rbf: 45%	$\approx 47\%$ (Литвинова)

Ключевой вывод

Предложенная **тематически-независимая методология** достигает точности, **сопоставимой** с лучшими существующими подходами, которые часто требуют глубокой очистки текста или привязки к тематике.

При этом методология применима к живым цифровым текстам (сленг, эмодзи, нарушения пунктуации) без потери качества.

Заключение

Результаты исследования

- **Разработана формализованная методология** извлечения лингвистических признаков из русскоязычного текста с минимальной предобработкой и без привязки к тематике.
- **Программный прототип** реализует полный цикл - от сырого текста до составного профиля.
- **Экспериментально подтверждена сопоставимость** с ведущими исследованиями:
 - Пол: точность **67%** (vs 70% у аналогов)
 - Возраст: точность **65%** (vs 68%)
 - Составной профиль: точность **45%** (vs 47%)

Научная значимость


Методология достигает сопоставимого качества **без агрессивной фильтрации** и **без контентной привязки**, что расширяет её применимость в реальных цифровых средах.

Спасибо за внимание!

Вопросы?

- Python: FastAPI, Scikit-learn, Pandas, Numpy, Seaborn, Matplotlib, Scipy
- NLP: Natasha, pymorphy2, nltk
- База данных: PostgreSQL
- Веб-сервер: Nginx
- Клиент: jQuery, Panini, Gulp
- Асинхронная обработка: Celery

Диаграмма компонентов



Архитектура развертывания системы

