Исследование и разработка методов автоматического профилирования автора русскоязычного текста

ИИПАмд-21 Филиппов Никита Андреевич

Научный руководитель: доцент кафедры ИС Воронина В.В.

Введение

Предметная область

Высокие требования к цифровым сервисам
Современные пользователи ожидают качественные и клиентоориентированные услуги. Бизнес стремится к повышению ключевых метрик: релевантным показам рекламы, высокой конверсии и снижению стоимости привлечения клиента

Проблема недостатка данных
Основная сложность в достижении этих показателей - отсутствие достоверной информации о пользователе сервиса. Традиционное ручное заполнение профилей (возраст, пол, интересы) часто игнорируется или сознательно искажается пользователями. По этой причине классические алгоритмы плохо справляются с задачей

Решение через анализ текста
Текст представляет собой цифровой отпечаток личности автора. Через его анализ можно извлечь множество характеристик, связанных с автором. Эта задача называется автоматическим профилированием текста

Актуальность

Бизнес-применение автоматического профилирования
Автоматическое профилирование автора текста позволяет решать ключевые бизнес-задачи цифровых платформ: персонализацию контента, таргетирование рекламы и глубокую аналитику аудитории без зависимости от ручного ввода данных.

- **Бизнес-потребность:** необходимость в персонализации, точном таргетинге и аналитике аудитории для улучшения ключевых метрик - снижения стоимости привлечения клиента, повышения показателя кликабельности и конверсии
- **Недостаток традиционных подходов:** текущие алгоритмы оказываются неэффективными при неполной или недостоверной информации о пользователе
- **Масштаб данных:** экспоненциальный рост пользовательского контента требует автоматизированных решений для анализа
- **Отсутствие готовых решений:** недосаток решений для автоматического профилирования русскоязычных текстов

Цели и задачи

Цель исследования

Разработка и экспериментальное обоснование эффективности веб-сервиса для автоматического профилирования автора текста, направленного на повышение точности персонализации цифровых платформ.

Задачи исследования

1. Обзор методов и подходов к автоматическому профилированию
2. Выбор и адаптация методов для русского языка
3. Разработка процесса извлечения и подготовки признаков
4. Обучение моделей машинного обучения
5. Проектирование и реализация веб-сервиса
6. Экспериментальная оценка и анализ результатов

Объект и предмет

- **Объект:** Процессы и методы анализа текстов для выявления характеристик автора
- **Предмет:** Алгоритмы и программные решения для автоматического профилирования автора русскоязычного текста

Научная новизна исследования

Контекст исследования
Работа представляет собой системное исследование и практическую реализацию методов автоматического профилирования автора текста, адаптированных для русскоязычных текстов.

- **Адаптация и систематизация существующих методов:** Проведено комплексное исследование современных подходов к автоматическому профилированию с учётом специфики русского языка
- **Формализация процесса профилирования:** Разработана формальная модель системы автоматического профилирования, обеспечивающая воспроизводимость результатов
- **Практическая реализация системы:** Создан работающий программный комплекс, объединяющий различные методы профилирования в единой системе с веб-интерфейсом и API

Методология

Состав профиля автора текста

Ключевые атрибуты профиля
Авторский профиль может включать различные характеристики: демографические, социальные, психологические и поведенческие. Среди них выделяются **первичные атрибуты** — пол и возраст, которые оказывают наиболее значимое влияние на стиль письма и служат основой для определения остальных характеристик.

Выбор атрибутов для исследования
В рамках данной работы для анализа выбраны **пол** и **возрастная группа** автора. Этот выбор обусловлен следующими причинами:

- Наличие размеченных данных для русского языка (корпус BlogsGenderAge)
- Хорошо изученные лингвистические маркеры
- Прямое практическое применение в задачах персонализации

Модель ’Как есть’

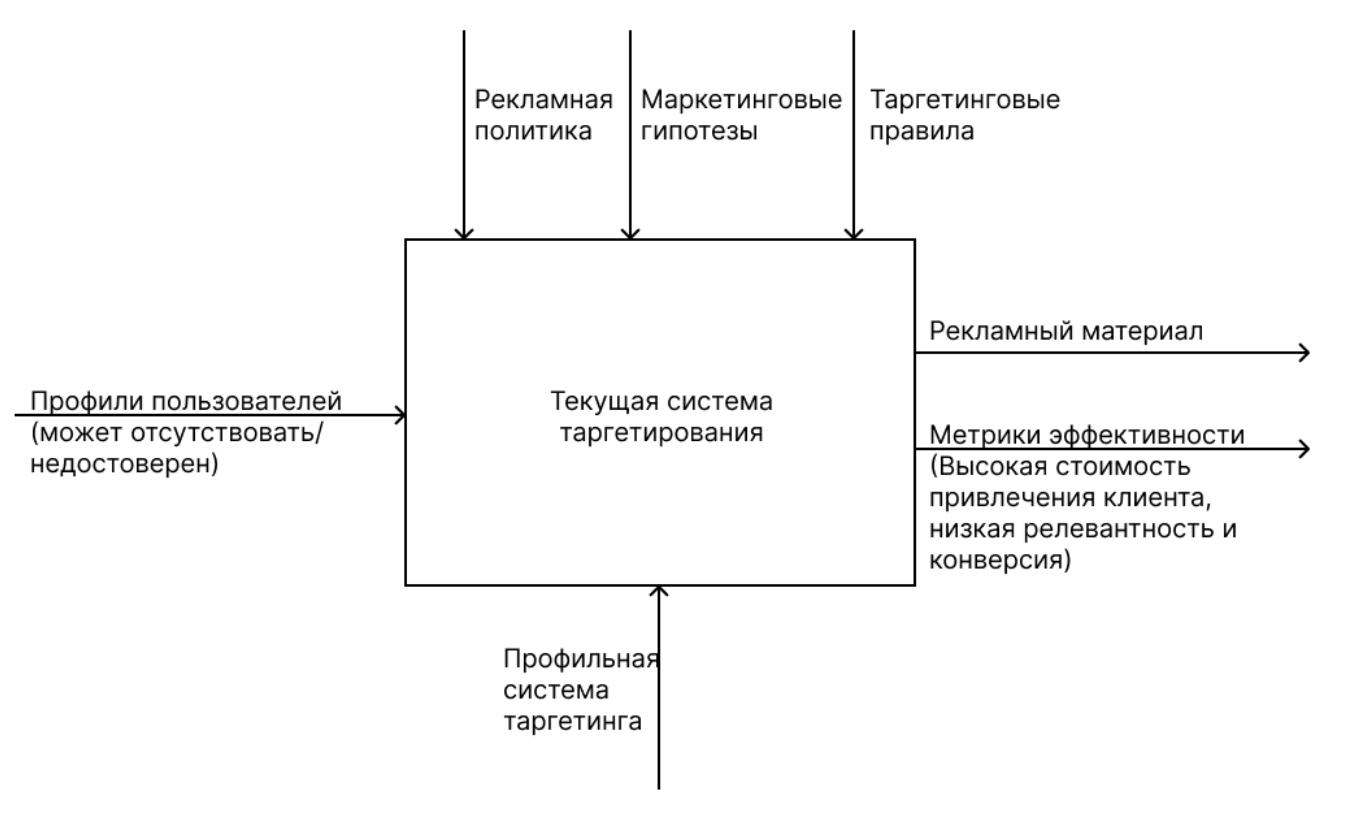

- Зависимость от профильных данных
- Низкая релевантность таргетинга
- Высокий CAC

Модель ’Как должно быть’

- Интеграция модуля автоматического профилирования
- Обогащение профилей на основе контента
- Повышение релевантности и снижение CAC

Существующие решения

Система	Основная функция	Ограничения для задачи профилирования
Bukvik LitTerra	Платформа для анализа текста: POS-разметка, анализ тональности, сетевой анализ, этимологический анализ, относительная энтропия	Фокус на атрибуции авторства и сравнительном анализе текстов
RuLex	Оценка сложности и читабельности текстов	Специализирован на оценке читабельности и педагогических метриках
Textometr	Многофункциональный лингвистический анализатор (сложность, читаемость, лексическое разнообразие, ключевые слова)	Специализирован на оценке читабельности и педагогических метриках

Вывод

- Существующие решения предоставляют отдельные компоненты, которые могут быть использованы для извлечения признаков
- Ни одна из рассмотренных систем не решает задачу автоматического составления демографического профиля автора

Подходы извлечения информации из текста

Стилометрический подход: лексика, морфология, синтаксис, пунктуация, TTR, длины слов/предложений

- Фокус на формальных характеристиках
- Устойчивость к тематическим сдвигам
- Меньшая зависимость от домена
- Чувствителен к объёму текста, уязвим к обфускации

Контекстный подход: ключевые слова, тематика, NER

- Фокус на тематике и семантике
- Высокая интерпретируемость
- Сильная зависимость от домена

Подходы в классификации составного профиля

Плоская классификация

- Одна модель для всех атрибутов
- Простота реализации
- Экспоненциальный рост классов
- Не работает в случае гетерогенных целевых переменных

Иерархическая классификация

- Последовательное уточнение атрибутов
- Использование специализированных моделей
- Более высокая точность

Теоретическое описание системы

Алгоритм обработки документа

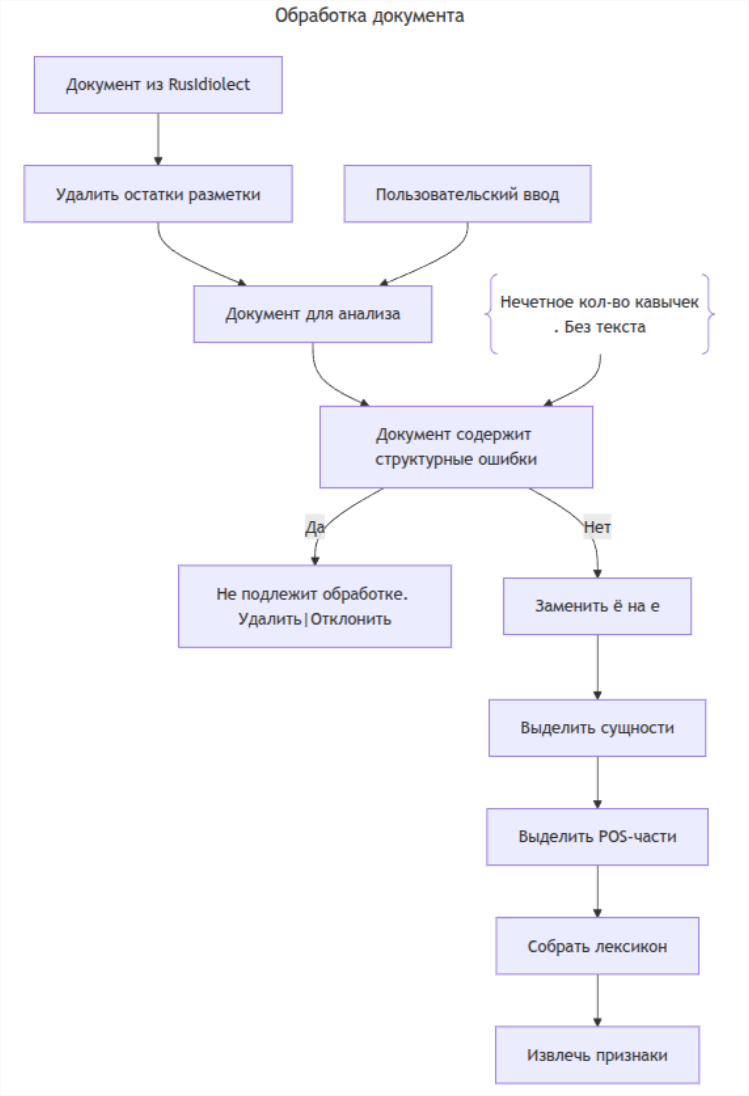

Рис. 1: Алгоритм обработки документа

План обучения моделей

- **Модели:** LR, SVM, Naive Bayes, KNN, RF, GBM, MLP
- **Гиперпараметры:** Подбор через GridSearchCV
- **Критерии:** Accuracy, Precision, Recall, F1-score, Матрицы ошибок
- **Валидация:** 5-фолдовая кросс-валидация

Проектирование системы

Диаграмма вариантов использования

Рис. 2: Варианты использования системы

Диаграмма классов системы

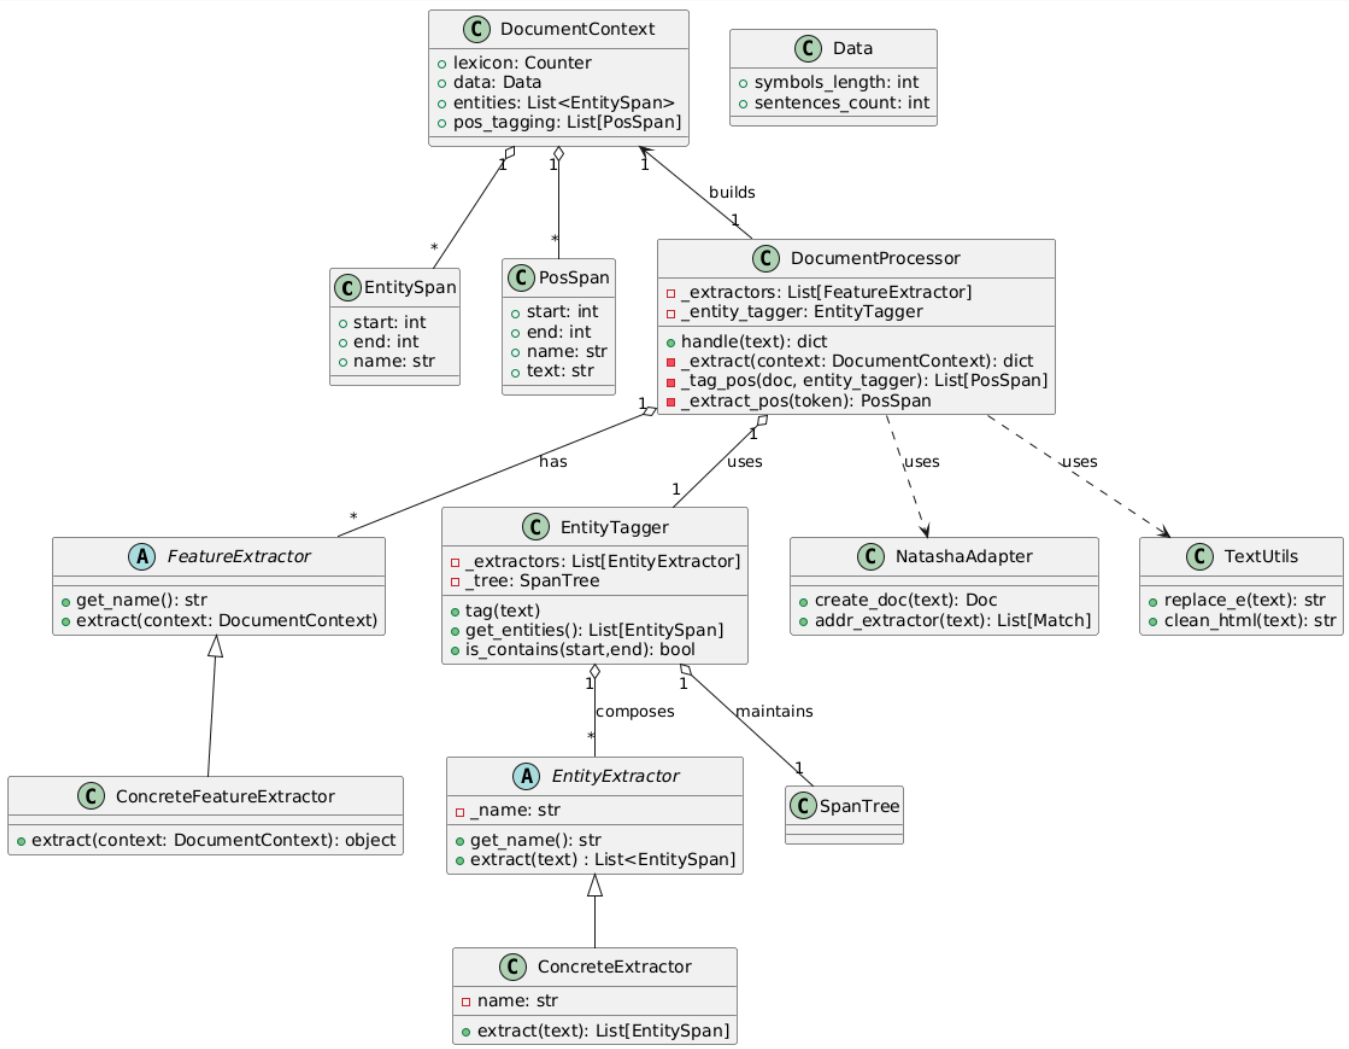

Рис. 3: Архитектура классов системы

Диаграмма последовательности

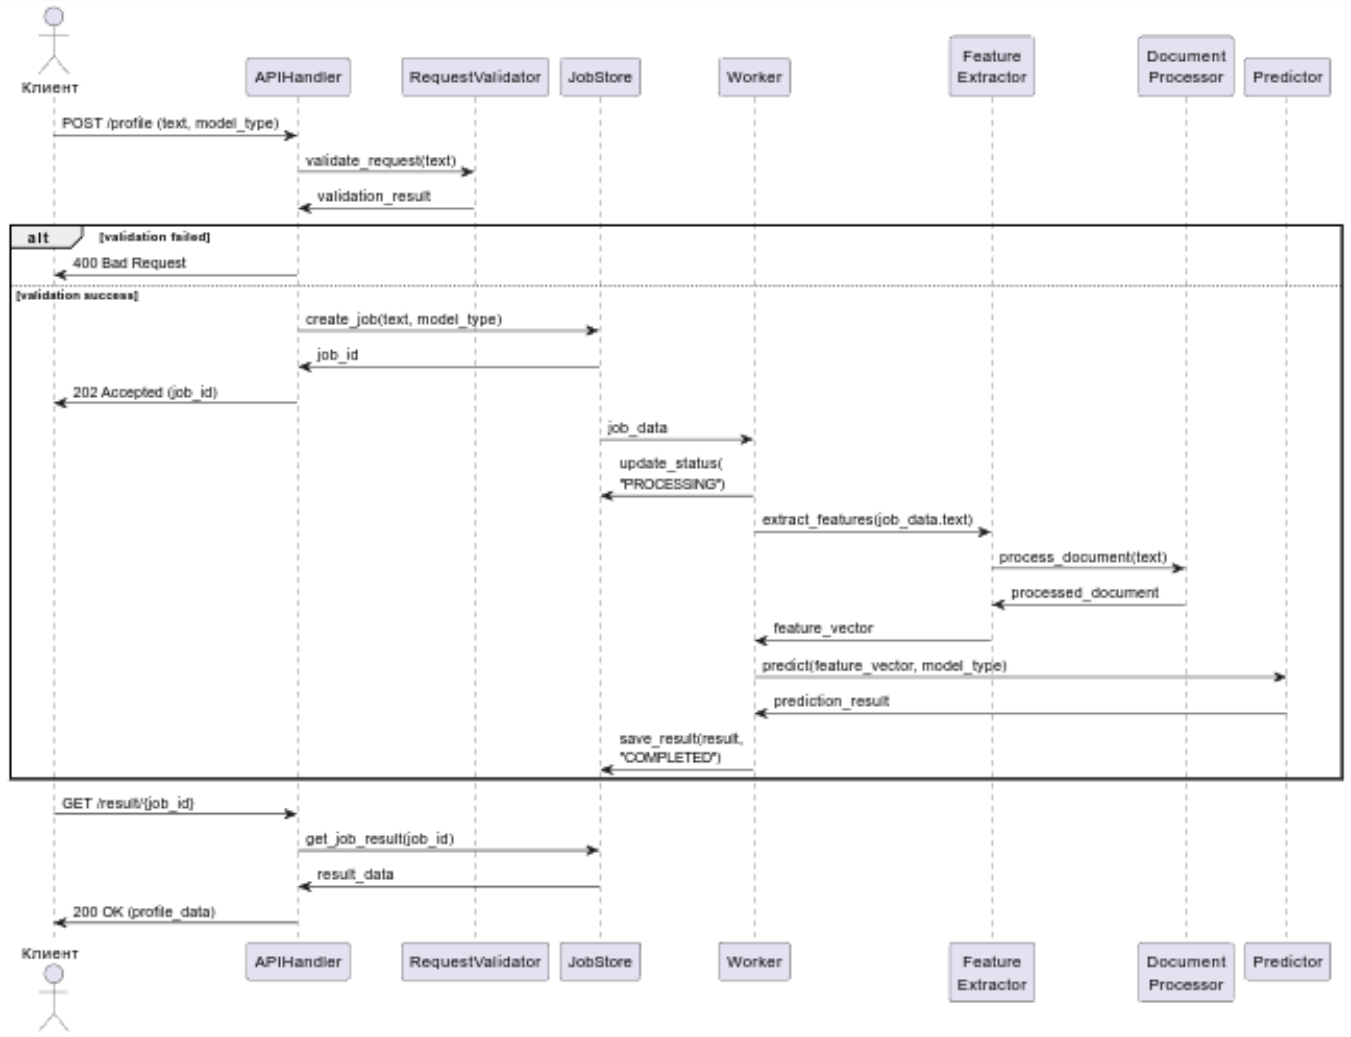

Рис. 4: Последовательность обработки запроса

Диаграмма компонентов

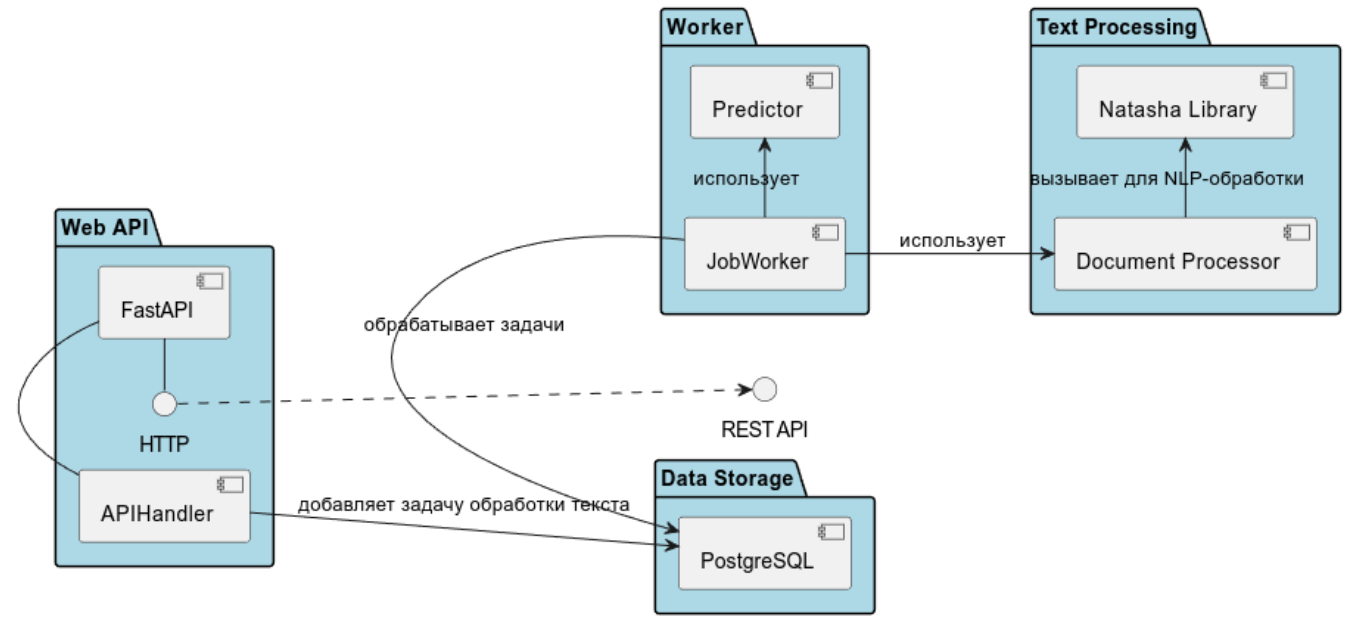

Рис. 5: Компонентная архитектура системы

Архитектура развертывания системы

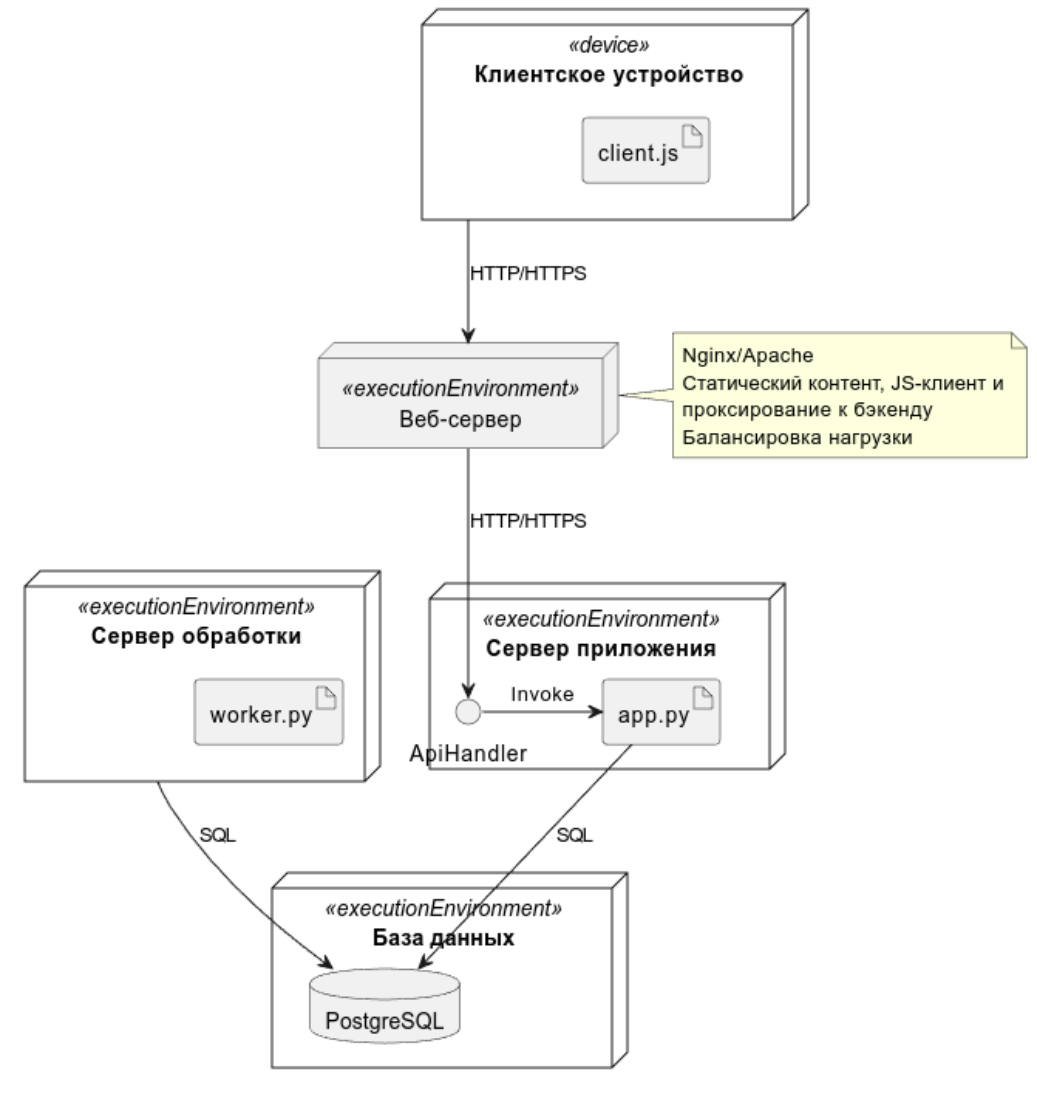

Рис. 6: Архитектура развертывания

Интерфейс пользователя. Главная страницаа

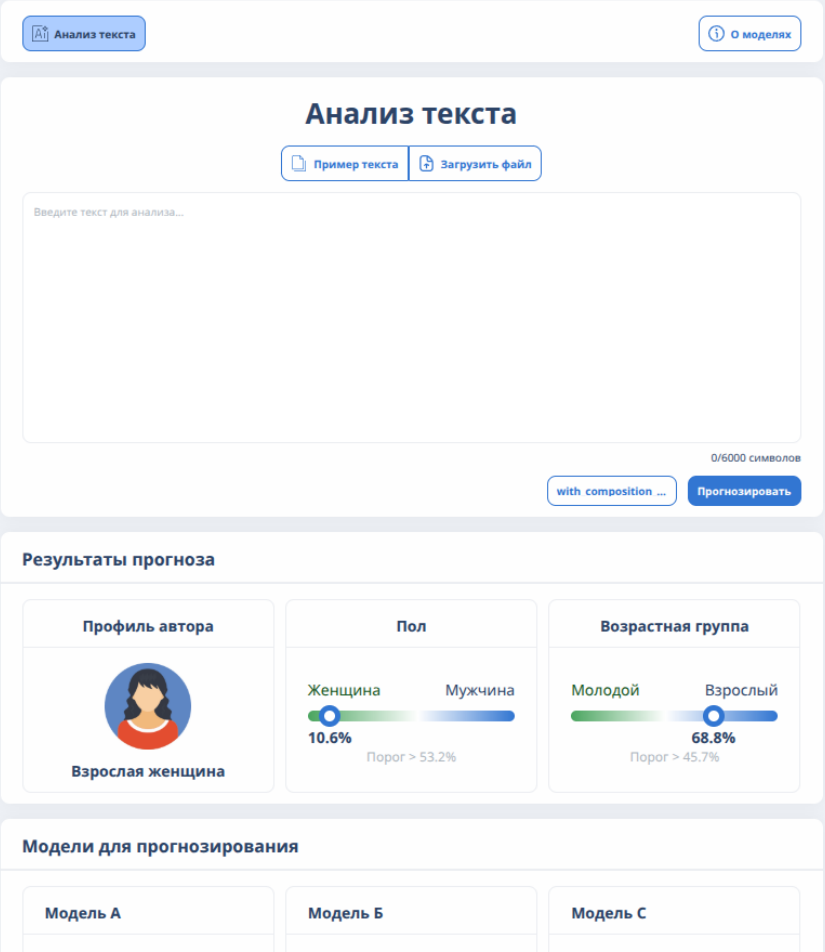

Интерфейс пользователя. Результат профилирования

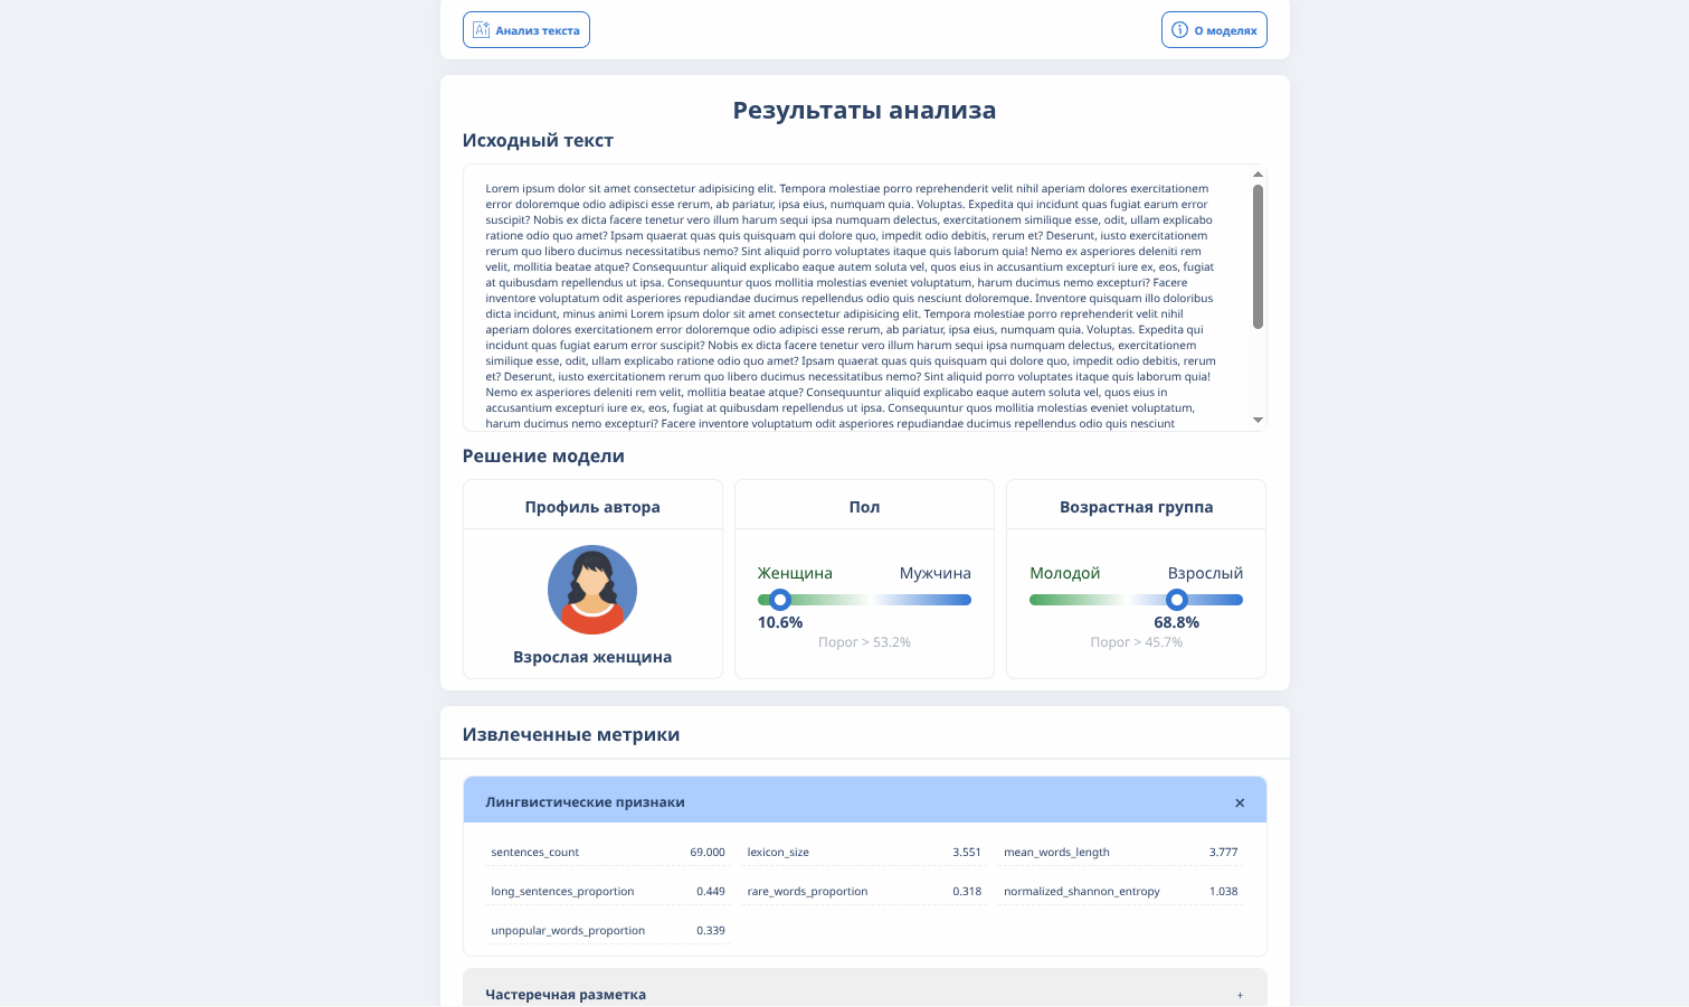

Интерфейс пользователя. Информация о модели

Анализ текста

О моделях

Доступные модели

Модель А

Модель Б

Модель С

Модель А

Общее

Для решения задачи автоматического определения демографических характеристик автора текста (пола и возрастной группы) была разработана специализированная архитектура нейронной сети, ориентированная на обработку стилометрических признаков.

Базовая структура

```
Input (65 features)
                        ├─ BatchNormalization
                        ├─ Dense(96) + GeLU Activation
                        ├─ Dropout(0.2)
                        ├─ Dense(64) + ReLU Activation
                        ├─ BatchNormalization
                        ├─ Dropout(0.1)
                        └─ Output (4 classes) + Softmax
```

Гиперпараметры обучения

Параметр	Значение	Описание
Оптимизатор	RMSprop	С адаптивной скоростью обучения
Learning Rate	0.0001	Фиксированная скорость обучения
Batch Size	32	Размер мини-батча
Epochs	150	Максимальное количество эпох
Early Stopping	Patience=15	Автоматическая остановка при переобучении
Loss Function	Categorical Crossentropy	Для многоклассовой классификации

Динамика обучения

Используемые технологии

- Python: FastAPI, Scikit-learn, Pandas, Numpy, Seaborn, Matplotlib, Scipy, Keras
- NLP: Natasha, pymorphy2, nltk
- База данных: PostgreSQL
- Веб-сервер: Nginx
- Клиент: jQuery, Panini, Gulp
- Асинхронная обработка: Celery

Текущее состояние проекта

Текущее состояние

Текущий статус
Разработан черновой прототип системы автоматического профилирования, включающий:

- Базовый пайплайн обработки текстовых данных
- Набор моделей машинного обучения для определения пола и возраста
- Веб-интерфейс для взаимодействия с системой

Задачи на доработку

Задачи на доработку

1. **Повторная предобработка данных** с учётом корректировок и требований от предприятия
2. **Разведывательный анализ данных** для выявления новых закономерностей и улучшения признакового пространства
3. **Обучение и эксперименты** с моделями с учётом обновлённых задач и требований
4. **Доведение прототипа до рабочего состояния** — интеграция, тестирование, оптимизация
5. **Подготовка примеров использования** и оформление информационных материалов

Спасибо за внимание!

Вопросы?